

AN INVESTIGATION INTO THE APPLICATION OF CONVOLUTIONAL NEURAL NETWORKS IN IMAGE CLASSIFICATION TASKS

Ngo Anh Duong, Nguyen Quang Vinh, Nguyen Huu Minh Hoang, Ha Thi Thanh Tam

University of Transport Technology, No. 54 Trieu Khuc Street, Thanh Liet Ward, Hanoi, Vietnam

Article info

Type of article:

Original research paper

Corresponding author:

Ha Thi Thanh Tam

E-mail address:

tamhtt@utt.edu.vn

Received:

Accepted:

Published:

Abstract: Environmental pollution, particularly the degradation of water quality and the increasing accumulation of waste, poses significant challenges to environmental management. This study aims to evaluate the applicability of the VGG-16 convolutional neural network architecture to two classification tasks: water turbidity classification and waste classification. The model was trained and tested on two separate datasets: a water turbidity dataset comprising 585 images representing five different turbidity levels, and a waste dataset consisting of 1300 images divided into four classes: organic, inorganic, hazardous, and recyclable waste. Preliminary experimental results show that the model achieved an accuracy of 92.86% for water turbidity classification and 90.13% for waste classification. This study provides an initial reference for the application of deep learning to environmental image analysis. However, due to the limited size of the test datasets, the model's generalization performance should be further evaluated using larger and independent datasets in future studies.

Keywords: Convolutional Neural Networks, VGG-16, Deep Learning, Computer Vision, Image Classification, Image Processing.

TÌM HIỂU VỀ ỨNG DỤNG MẠNG NƠ RON TÍCH CHẬP TRONG MỘT SỐ BÀI TOÁN PHÂN LOẠI ẢNH

Ngô Ánh Dương, Nguyễn Quang Vinh, Nguyễn Hữu Minh Hoàng, Hà Thị Thanh Tâm

Trường Đại học Công nghệ Giao thông vận tải, Số 54 Triều Khúc, phường Thanh Liệt, Hà Nội, Việt Nam

Thông tin bài viết

Tác giả liên hệ:

Hà Thị Thanh Tâm

Địa chỉ E-mail:

tamhtt@utt.edu.vn

Ngày nộp bài:

Ngày chấp nhận:

Ngày đăng bài:

Tóm tắt: Ô nhiễm môi trường, đặc biệt là suy giảm chất lượng nước và gia tăng rác thải, đang đặt ra thách thức lớn trong công tác quản lý. Nghiên cứu này nhằm mục đích đánh giá khả năng áp dụng của kiến trúc mạng nơ ron tích chập VGG-16 vào hai bài toán: phân loại độ đục của nước và phân loại rác thải. Mô hình được huấn luyện và thử nghiệm trên hai bộ dữ liệu riêng biệt: bộ dữ liệu độ đục của nước gồm 585 ảnh thuộc năm mức độ đục khác nhau và bộ dữ liệu rác thải gồm 1300 ảnh chia thành bốn lớp (hữu cơ, vô cơ, nguy hại, tái chế). Kết quả thực nghiệm bước đầu cho thấy mô hình đạt độ chính xác 92.86% đối với bài toán phân loại độ đục của nước và 90.13% đối với bài toán phân loại rác thải. Nghiên cứu cung cấp cơ sở tham khảo ban đầu về việc ứng dụng học sâu trong thị giác môi trường. Tuy nhiên, do kích thước các tập dữ liệu kiểm tra còn hạn chế, hiệu năng tổng quát hóa của mô hình cần tiếp tục được đánh giá trên các bộ dữ liệu độc lập và quy mô lớn hơn trong tương lai.

Từ khóa: Mạng nơ ron tích chập, VGG-16, học sâu, thị giác máy tính, phân loại ảnh, xử lý ảnh.

1. Tổng quan

1.1. Tổng quan mạng nơ ron

Mạng nơ ron nhân tạo (Artificial Neural Network – ANN), thường được gọi ngắn gọn là mạng nơ ron (Neural Network, NN), là một mô hình được xây dựng dựa trên nguyên lý hoạt động của hệ thần kinh. Ý tưởng về mạng nơ ron nhân tạo được đề xuất lần đầu tiên bởi Warren McCulloch và Walter Pitts [1] năm 1943. Nghiên cứu này đã đặt nền móng cho sự phát triển của lĩnh vực mạng nơ ron và trí tuệ nhân tạo hiện đại.

Mỗi mạng nơ ron bao gồm nhiều nơ ron, được liên kết với nhau thông qua các trọng số để mô phỏng quá trình xử lý thông tin của não bộ. Dữ liệu được truyền từ lớp đầu vào qua một hoặc

nhiều lớp ẩn, sau đó tạo ra kết quả tại lớp đầu ra. Quá trình huấn luyện mạng nơ ron bao gồm hai giai đoạn chính là lan truyền tiến và lan truyền ngược. Trong quá trình này, các trọng số được cập nhật liên tục nhằm giảm thiểu sai số giữa kết quả dự đoán và giá trị thực tế, từ đó giúp mô hình học được các đặc trưng của dữ liệu [1], [2].

Một mạng nơ ron cơ bản gồm ba thành phần chính:

- Lớp đầu vào (Input Layer): Tiếp nhận dữ liệu đầu vào của mô hình.
- Lớp ẩn (Hidden Layer): Thực hiện các phép biến đổi và trích xuất đặc trưng từ dữ liệu.
- Lớp đầu ra (Output Layer): Đưa ra kết quả dự đoán cuối cùng.

Đối với một nơ ron, tổng tín hiệu đầu vào được xác định theo công thức [2]:

$$h = g(W^T x + b) \quad (1)$$

trong đó:

- x : vectơ dữ liệu đầu vào
- W^T : vectơ trọng số
- b : hệ số bù (bias)
- g : hàm kích hoạt
- h : giá trị đầu ra của nơ ron

Mạng nơ ron truyền thẳng, tên tiếng anh là Feedforward Neural Network (FNN) là dạng đơn giản nhất của mạng nơ ron. Nền tảng của mô hình này được đặt ra bởi Frank Rosenblatt thông qua mô hình Perceptron được công bố vào năm 1958 [3]. Trong kiến trúc này, dữ liệu được truyền theo một chiều từ lớp đầu vào, qua các lớp ẩn và đến lớp đầu ra mà không tồn tại cơ chế phản hồi ngược [1], [3]. FNN được ứng dụng rộng rãi trong các bài toán phân loại và dự đoán dữ liệu nhờ cấu trúc đơn giản và khả năng mô hình hóa các mối quan hệ phi tuyến.

Cấu trúc của FNN bao gồm các lớp kết nối đầy đủ, trong đó mỗi nơ ron ở một lớp sẽ được kết nối với tất cả nơ ron của lớp kế tiếp.

Quá trình lan truyền trong FNN được biểu diễn như sau:

$$a^{(l)} = g(W^{(l)} a^{(l-1)} + b^{(l)}) \quad (2)$$

trong đó:

- $a^{(l)}$: đầu ra của lớp thứ l
- $W^{(l)}$: là ma trận trọng số
- $b^{(l)}$: vectơ độ lệch
- g : hàm kích hoạt

FNN được ứng dụng rộng rãi trong các bài toán phân loại và dự đoán dữ liệu dạng bảng. Tuy nhiên, đối với bài toán xử lý ảnh, mô hình này bộc lộ nhiều hạn chế do phải chuyển đổi ảnh thành vectơ một chiều, làm mất đi thông tin không gian giữa các điểm ảnh và gia tăng đáng kể số lượng tham số cần huấn luyện [2], [3].

Mạng nơ ron sâu, tên tiếng anh là Deep Neural Network (DNN), là sự phát triển của mạng nơ ron truyền thẳng bằng cách bổ sung nhiều lớp

ẩn nhằm tăng khả năng học các đặc trưng phức tạp của dữ liệu [2], [4]. Khái niệm này được phát triển và hoàn thiện bởi nhiều nhà nghiên cứu, nổi bật là Geoffrey Hinton, Yann LeCun và Yoshua Bengio [4]. Nhờ khả năng biểu diễn dữ liệu ở nhiều mức độ trừu tượng khác nhau, DNN đã trở thành nền tảng quan trọng cho sự phát triển của lĩnh vực học sâu.

Không giống như các mô hình truyền thống, DNN có khả năng học các biểu diễn dữ liệu ở nhiều mức độ trừu tượng khác nhau. Các lớp đầu tiên thường học những đặc trưng cơ bản, trong khi các lớp phía sau sẽ kết hợp chúng để tạo thành các đặc trưng phức tạp hơn [4].

Cấu trúc tổng quát của DNN được mô tả như sau:

$$x \rightarrow h_1 \rightarrow h_2 \rightarrow \dots \rightarrow h_n \rightarrow y \quad (3)$$

trong đó:

- x là dữ liệu đầu vào
- h_i là các lớp ẩn
- y là kết quả đầu ra.

Mặc dù, DNN đạt hiệu quả cao trong nhiều lĩnh vực, việc huấn luyện các mô hình có số lượng lớp lớn thường đòi hỏi khối lượng dữ liệu lớn, thời gian xử lý dài và tài nguyên tính toán mạnh [2], [4].

FNN, DNN và mạng nơ ron tích chập, tên tiếng anh là Convolutional Neural Network (CNN), đều là các biến thể của mạng nơ ron nhưng có sự khác biệt về cấu trúc và phương pháp xử lý dữ liệu. FNN sử dụng các lớp kết nối đầy đủ và phù hợp với dữ liệu dạng bảng. DNN phát triển FNN bằng cách bổ sung thêm nhiều lớp ẩn nhằm tăng khả năng học đặc trưng. Trong khi đó, CNN được thiết kế chuyên biệt cho dữ liệu hình ảnh thông qua các lớp tích chập và lớp gộp, giúp mô hình bảo toàn được thông tin không gian và giảm số lượng tham số cần huấn luyện [2], [4].

Nhờ những ưu điểm này, CNN hiện được ứng dụng rộng rãi trong các bài toán thị giác máy tính, nhận dạng đối tượng và phân loại ảnh.

Mặc dù các kiến trúc mạng nơ ron tích chập đã đạt được nhiều thành tựu trong thị giác máy

tính, việc áp dụng CNN vào các bài toán giám sát môi trường thực tế như đánh giá độ đục của nước và phân loại rác thải vẫn gặp nhiều thách thức. Hạn chế lớn nhất xuất phát từ việc tập dữ liệu thực tế thường có quy mô nhỏ, trong khi sự chênh lệch thị giác giữa các mức độ đục hoặc các loại rác thải là rất nhỏ, dễ dẫn đến hiện tượng quá khớp và sai lệch phân loại.

Xuất phát từ thực trạng đó, nghiên cứu này đặt ra giả thuyết rằng việc sử dụng kiến trúc VGG-16 kết hợp với kỹ thuật học chuyển giao (Transfer Learning) sẽ giúp tận dụng hiệu quả các đặc trưng thị giác cấp cao đã được huấn luyện trước trên tập ImageNet, từ đó nâng cao độ chính xác phân loại cho các bài toán môi trường có dung lượng dữ liệu hạn chế.

Các đóng góp chính của bài báo bao gồm:

- Về dữ liệu: Xây dựng, tiền xử lý hai tập dữ liệu ảnh thực tế phục vụ đánh giá chất lượng nước (585 ảnh) và phân loại rác thải (1300 ảnh).
- Về quy trình: Đề xuất quy trình tinh chỉnh mạng VGG-16 tích hợp lớp Dropout và cơ chế dừng sớm (Early Stopping) giúp tối ưu hóa thời gian huấn luyện và hạn chế quá khớp trên dữ liệu nhỏ.
- Về đánh giá: Cung cấp chi tiết kết quả dự đoán thực tế và bộ chỉ số đo lường (Accuracy, Precision, Recall, F1-score), làm rõ hiệu năng cũng như hạn chế thực tế của mô hình VGG-16.

1.2. Tổng quan các nghiên cứu gần đây

1.2.1. Nghiên cứu về phân loại rác

Các nghiên cứu gần đây cho thấy CNN được sử dụng ngày càng phổ biến trong nhận dạng và phân loại rác từ hình ảnh. Một nghiên cứu tổng quan của Wu và cộng sự đã tổng hợp 355 công trình về ứng dụng CNN trong nhận dạng và tái chế rác, trong đó tập trung vào ba nhóm nhiệm vụ chính gồm nhận dạng vật liệu có thể tái chế, phát hiện ô nhiễm do rác và phân loại chất thải rắn [5].

Một số nghiên cứu cũng đã áp dụng các kiến trúc học VGG cho phân loại rác. Chẳng hạn, nghiên cứu về phân loại chất thải xây dựng đã sử dụng các kiến trúc VGG kết hợp học chuyển giao và tăng cường dữ liệu, trong đó VGG-16 đạt độ

chính xác 76,6% [6].

1.2.2. Nghiên cứu về phân loại độ đục của nước

Năm 2025, Soto và cộng sự đã đề xuất phương pháp phân loại độ đục của nước dựa trên hình ảnh sử dụng mạng CNN kết hợp học chuyển giao với kiến trúc EfficientNet-B0. Nghiên cứu phân loại các mẫu nước thành năm nhóm độ đục và đạt độ chính xác trung bình 99% qua mười lần huấn luyện độc lập [7].

Một nghiên cứu khác của Nie và cộng sự công bố năm 2025 tập trung vào bài toán phân loại độ đục từ hình ảnh. Các tác giả chỉ ra rằng sự thay đổi về độ đục có thể tạo ra những khác biệt rất nhỏ trong hình ảnh, gây khó khăn cho việc phân loại bằng phương pháp trực quan. Nghiên cứu đã xây dựng và đánh giá mô hình CNN, trong đó mô hình CNN-10 có thêm lớp Dropout đạt độ chính xác 96,5% trên dữ liệu có nhiễu [8].

1.2.3. Học chuyển giao trong phân loại ảnh

Đối với bài toán có số lượng dữ liệu huấn luyện hạn chế, học chuyển giao là một hướng tiếp cận có hiệu quả. Thay vì huấn luyện mô hình hoàn toàn từ đầu, các trọng số được học từ một tập dữ liệu lớn có thể được sử dụng làm cơ sở cho bài toán mới. Các nghiên cứu tổng quan về học chuyển giao cho phân loại ảnh cho thấy phương pháp này đặc biệt hữu ích trong những trường hợp số lượng dữ liệu gán nhãn còn hạn chế.

Trong nghiên cứu này, VGG-16 được lựa chọn làm mô hình thực nghiệm và kết hợp với học chuyển giao. Việc lựa chọn này phù hợp với quy mô dữ liệu của nghiên cứu, đồng thời cho phép đánh giá khả năng của cùng một kiến trúc CNN trên hai bài toán có đặc điểm hình ảnh khác nhau.

2. Kiến thức cơ sở

Sự phát triển của CNN đã tạo nên nhiều bước tiến quan trọng trong lĩnh vực thị giác máy tính. Nhiều kiến trúc CNN được đề xuất nhằm nâng cao khả năng học đặc trưng, cải thiện độ chính xác và tối ưu hiệu quả tính toán trong các bài toán phân loại ảnh. Trong số đó, LeNet-5, AlexNet và VGGNet được xem là những kiến trúc tiêu biểu,

đánh dấu các cột mốc quan trọng trong quá trình phát triển của học sâu và đặt nền tảng cho nhiều mô hình CNN hiện đại.

2.1. Cơ sở lý thuyết về CNN

CNN là một loại mạng nơ ron học sâu được thiết kế đặc biệt để xử lý các dữ liệu có cấu trúc dạng lưới. Dạng dữ liệu phổ biến nhất mà CNN xử lý là hình ảnh, được biểu diễn dưới dạng ma trận hai chiều của các điểm ảnh trên từng kênh màu. Ý tưởng về CNN được phát triển bởi Yann LeCun cùng các cộng sự vào cuối những năm 1980 và được giới thiệu rộng rãi trong bài báo "*Gradient-Based Learning Applied to Document Recognition*" công bố trên *Proceedings of the IEEE* năm 1998 [9]. Kiến trúc CNN lần đầu được giới thiệu trong bài báo này là mô hình LeNet-5 cho bài toán nhận dạng chữ viết tay. Mô hình này đã đặt nền tảng cho sự phát triển của các kiến trúc CNN hiện đại. Năm 2012, sự ra đời của AlexNet đã tạo nên bước đột phá trong cuộc thi thử thách nhận dạng hình ảnh (ImageNet Large Scale Visual Recognition Challenge), khi đạt độ chính xác vượt trội so với các phương pháp truyền thống, qua đó khẳng định hiệu quả của học sâu trong bài toán phân loại ảnh [10]. Trên cơ sở đó, nhiều kiến trúc CNN có độ sâu lớn hơn như VGGNet và ResNet đã lần lượt được phát triển nhằm nâng cao khả năng học biểu diễn và cải thiện hiệu năng phân loại dữ liệu [11], [12].

Một mạng CNN bao gồm nhiều lớp được liên kết tuần tự với nhau để thực hiện quá trình trích xuất đặc trưng và phân loại dữ liệu. Các thành phần chính của CNN gồm:

- Lớp tích chập (Convolutional Layer): thực hiện phép tích chập giữa ảnh đầu vào và các bộ lọc (Kernel/Filter) để tạo ra các bản đồ đặc trưng.
- Lớp kích hoạt (Activation Layer): áp dụng hàm kích hoạt nhằm tăng khả năng biểu diễn phi tuyến của mô hình, trong đó phổ biến nhất là hàm ReLU (Rectified Linear Unit).
- Lớp gộp (Pooling Layer): giảm kích thước của bản đồ đặc trưng, giữ lại các đặc trưng quan trọng và giảm chi phí tính toán.

- Lớp kết nối đầy đủ (Fully Connected Layer): tổng hợp các đặc trưng đã học và thực hiện quá trình phân loại thông qua hàm Softmax.

Tại lớp tích chập, đầu ra của một đặc trưng được tính theo công thức:

$$y(i, j) = \sum_{m=0}^{k-1} \sum_{n=0}^{k-1} x(i+m, j+n)w(m, n) + b \quad (4)$$

trong đó:

- $x(i+m, j+n)$: giá trị điểm ảnh đầu vào
- $w(m, n)$: trọng số của bộ lọc
- b : hệ số dịch (bias)
- $y(i, j)$: giá trị của bản đồ đặc trưng sau phép tích chập.

Sau lớp tích chập, hàm kích hoạt ReLU được sử dụng để loại bỏ các giá trị âm và tăng khả năng học của mô hình:

$$f(x) = \max(0, x) \quad (5)$$

Tiếp theo, lớp Max Pooling thực hiện giảm kích thước đặc trưng bằng cách giữ lại giá trị lớn nhất trong mỗi vùng quan sát:

$$y = \max(x_1, x_2, \dots, x_n) \quad (6)$$

Cuối cùng, sau khi dữ liệu được làm phẳng (Flatten), lớp kết nối đầy đủ sử dụng hàm Softmax để tính xác suất mẫu dữ liệu thuộc từng lớp:

$$P(y=i) = \frac{e^{z_i}}{\sum_{j=1}^C 1e^{z_j}} \quad (7)$$

trong đó:

- z_i : giá trị đầu ra của lớp thứ i
- C : số lớp cần phân loại
- $P(y=i)$: xác suất mẫu dữ liệu thuộc lớp i .

Nhờ khả năng tự động học và trích xuất đặc trưng theo nhiều mức độ từ dữ liệu đầu vào, CNN đã chứng minh hiệu quả vượt trội so với các phương pháp xử lý ảnh truyền thống trong nhiều bài toán phân loại ảnh. Đồng thời, sự phát triển của các kiến trúc CNN hiện đại đã góp phần nâng cao đáng kể độ chính xác, khả năng tổng quát

hóa và hiệu quả tính toán, mở rộng phạm vi ứng dụng của học sâu trong nhiều lĩnh vực như y tế, nông nghiệp, giao thông, công nghiệp và bảo vệ môi trường.

2.2. Tổng quan về bài toán phân loại ảnh

2.2.1. Khái niệm và phân loại bài toán

Phân loại ảnh, tên tiếng anh là Image Classification, là một trong những bài toán nền tảng của lĩnh vực thị giác máy tính, với mục tiêu xác định và gán nhãn cho một hình ảnh dựa trên nội dung mà hình ảnh đó chứa.

Các phương pháp phân loại ảnh truyền thống thường yêu cầu quá trình thiết kế đặc trưng thủ công trước khi đưa dữ liệu vào bộ phân loại. Tuy nhiên, cách tiếp cận này phụ thuộc nhiều vào kinh nghiệm của người nghiên cứu và thường gặp khó khăn khi xử lý các tập dữ liệu có kích thước lớn hoặc chứa nhiều đặc trưng phức tạp. Sự ra đời của CNN đã thay đổi đáng kể cách tiếp cận bài toán phân loại ảnh khi cho phép mô hình tự động học và trích xuất đặc trưng trực tiếp từ dữ liệu đầu vào, từ đó cải thiện đáng kể hiệu quả phân loại và khả năng tổng quát hóa của mô hình [4], [10].

Bài toán phân loại ảnh là quá trình xây dựng mô hình có khả năng ánh xạ một hình ảnh đầu vào vào một hoặc nhiều lớp nhãn đã được xác định trước. Trong quá trình huấn luyện, mô hình học các đặc trưng của từng lớp dữ liệu thông qua tập dữ liệu đã gán nhãn. Khi nhận một ảnh mới, mô hình sẽ phân tích các đặc trưng đã học và đưa ra dự đoán lớp có xác suất cao nhất [4].

Dựa trên số lượng nhãn và đặc điểm của tập dữ liệu, bài toán phân loại ảnh thường được chia thành ba dạng chính, bao gồm phân loại nhị phân, phân loại đa lớp và phân loại đa nhãn. Trong đó, phân loại nhị phân là bài toán mà mỗi ảnh chỉ được gán vào một trong hai lớp dữ liệu, chẳng hạn như xác định ảnh có hoặc không chứa đối tượng cần nhận diện. Đối với phân loại đa lớp, mỗi ảnh chỉ thuộc duy nhất một lớp trong nhiều lớp đã được xác định trước. Đây là dạng bài toán phổ biến nhất trong lĩnh vực phân loại ảnh và được ứng dụng rộng rãi trong nhiều nghiên cứu, điển hình như phân loại rác thành các nhóm rác hữu cơ, rác vô cơ, rác nguy hại và rác tái chế

hoặc phân loại các mức độ đục của nước. Trong khi đó, phân loại đa nhãn là bài toán mà một ảnh có thể đồng thời thuộc nhiều lớp khác nhau. Loại bài toán này thường xuất hiện trong các hệ thống nhận dạng cảnh hoặc nhận dạng nhiều đối tượng cùng lúc trong một hình ảnh, khi mỗi ảnh có thể chứa nhiều đối tượng hoặc nhiều thuộc tính cần được gán nhãn.

Trong nghiên cứu này, hai bài toán được thực nghiệm là phân loại rác và phân loại độ đục của nước đều thuộc dạng phân loại đa lớp, tức là mỗi ảnh chỉ được gán vào một nhãn duy nhất.

2.2.2. Các tiêu chí đánh giá bài toán phân loại ảnh

Để đánh giá hiệu quả của một mô hình phân loại và xác định mức độ chính xác cũng như khả năng tổng quát hóa dữ liệu. Các chỉ số phổ biến thường được sử dụng bao gồm:

Accuracy (Độ chính xác): Là chỉ số biểu thị tỷ lệ số lượng dự đoán đúng của mô hình trên tổng số mẫu dữ liệu được đánh giá. Giá trị Accuracy càng cao chứng tỏ mô hình có khả năng phân loại càng tốt [13].

$$\begin{aligned} \text{Accuracy} &= \frac{\text{Số mẫu phân loại đúng}}{\text{Tổng số mẫu phân loại}} \\ &= \frac{TP + TN}{TP + TN + FP + FN} \end{aligned} \quad (8)$$

trong đó TP , tên tiếng anh là True Positive, là số lượng mẫu thuộc lớp dương được dự đoán đúng, TN (True Negative) là số lượng mẫu thuộc lớp âm được dự đoán đúng, FP (False Positive) là số lượng mẫu thuộc lớp âm nhưng bị dự đoán sai thành lớp dương, FN (False Negative) là số lượng mẫu thuộc lớp dương nhưng bị dự đoán sai thành lớp âm.

Precision (Độ chính xác dương): Đo lường tỷ lệ các mẫu được dự đoán là dương tính mà thực tế cũng thuộc lớp dương tính, giúp đánh giá độ tin cậy của các dự đoán dương [13].

$$\begin{aligned} \text{Precision} &= \frac{\text{Số lượng mẫu dương dự đoán đúng}}{\text{Tổng số mẫu được dự đoán là đúng}} \\ &= \frac{TP}{TP + FP} \end{aligned} \quad (9)$$

Recall (Độ bao phủ): Phản ánh khả năng của mô hình trong việc phát hiện đầy đủ các mẫu thực sự thuộc lớp dương tính trong tập dữ liệu [13].

$$Recall = \frac{TP}{TP + FN} \quad (10)$$

F1-score là trung bình điều hòa của Precision và Recall, được sử dụng để đánh giá tổng hợp

hiệu quả của mô hình, đặc biệt trong trường hợp dữ liệu giữa các lớp không cân bằng [13].

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (11)$$


Bên cạnh các chỉ số định lượng, Confusion Matrix (Ma trận nhầm lẫn) là một công cụ quan trọng để phân tích chi tiết kết quả, biểu diễn số lượng dự đoán đúng và sai của từng lớp đối tượng, giúp người nghiên cứu nhận diện các lỗi nhầm lẫn cụ thể của mô hình [13].

3. Thực nghiệm và đánh giá

Trong bài này, lấy ý tưởng từ bài báo “*An improved CNN model in image classification application in water turbidity*”, chúng tôi thử nghiệm lại trên mô hình VGG16 kết hợp học chuyển giao cho bài toán phân loại độ đục của nước với tập dữ liệu được chúng tôi tự thu thập bằng camera của điện thoại. Trên cơ sở đó, chúng tôi cũng thử nghiệm mô hình với việc phân loại các loại rác thải sinh hoạt thường thấy trong các siêu thị hoặc trung tâm thương mại lớn. Nhóm mong muốn với việc chụp ảnh bằng camera thông thường vẫn có thể dự báo được khi xây dựng một ứng dụng nhận diện ảnh.

3.1. Quy trình thực nghiệm

Quy trình thực nghiệm trong nghiên cứu này được xây dựng chung cho cả hai bài toán phân loại rác và phân loại độ đục của nước, bao gồm các bước như trong Hình 4.



Hình 4. Quy trình thực nghiệm

- Thu thập dữ liệu: Dữ liệu hình ảnh được chúng tôi thu thập bằng cùng một camera điện thoại dưới điều kiện ánh sáng tiêu chuẩn (ánh sáng tự nhiên hay ánh sáng trong phòng nhưng phải có nhiều ánh đèn màu trắng đảm bảo đủ độ sáng, cùng màu đèn) với khoảng cách cố định 20 cm - 30 cm, đảm bảo chất lượng ảnh và tính đa dạng về góc chụp. Sau khi thu thập, dữ liệu được tiền xử lý ảnh đưa về dạng chuẩn 224x224 pixel. Các ảnh được sàng lọc theo các tiêu chí: loại bỏ các ảnh bị mờ, thiếu sáng. Quá trình gán nhãn dữ liệu được thực hiện thống nhất bởi 1 thành viên nhóm nghiên cứu.

- Phân chia dữ liệu: Dữ liệu được phân chia thành ba tập dữ liệu độc lập gồm: tập dữ liệu huấn luyện (Training Dataset), tập dữ liệu kiểm định (Validation Dataset) và tập dữ liệu kiểm tra (Testing Dataset). Đối với các tập dữ liệu có quy mô nhỏ như bộ dữ liệu nước, nhóm tăng cường dữ liệu bằng cách tạo nhiễu như nhiễu Gaussian, nhiễu muối tiêu. Các ảnh nhiễu này chỉ sử dụng trên tập huấn luyện nhằm tăng tính đa dạng của dữ liệu. Các ảnh của tập kiểm định và tập kiểm tra được giữ nguyên bản 100% ảnh gốc thực tế để đảm bảo tính minh bạch và chính xác khi đánh giá mô hình.

- Xây dựng mô hình: Mô hình được xây dựng dựa trên kiến trúc VGG16 kết hợp kỹ thuật học chuyển giao và được huấn luyện trên nền tảng Google Colab sử dụng GPU nhằm tăng tốc quá trình xử lý. Trong quá trình xây dựng, các trọng số đã được huấn luyện trước trên tập dữ liệu ImageNet được sử dụng, đồng thời các lớp phân loại cuối cùng của VGG16, bao gồm lớp Flatten, hai lớp Fully Connected (4096 nơ ron) và lớp Softmax đầu ra gồm 1000 lớp, được loại bỏ thông qua việc thiết lập tham số `include_top = False`. Sau đó, các lớp mới được bổ sung bao gồm lớp Flatten, lớp Dense gồm 128 nơ ron sử dụng hàm kích hoạt ReLU, lớp Dropout với tỷ lệ 0.5 và lớp Dense đầu ra sử dụng hàm Softmax nhằm phù hợp với bài toán phân loại độ đục của nước và rác thải. Đồng thời, kỹ thuật Early Stopping được tích hợp để tự động dừng quá trình huấn luyện khi độ lỗi trên tập kiểm định không còn cải thiện, giúp tối ưu hóa hiệu năng mô

hình. Sau đó, dữ liệu được đưa vào mô hình để tiến hành huấn luyện.

- **Đánh giá kết quả:** Sau quá trình huấn luyện, mô hình được đánh giá trên tập dữ liệu kiểm tra thông qua các tiêu chí gồm Accuracy, Precision, Recall và F1-score nhằm đánh giá khả năng hội tụ, hiệu năng phân loại và khả năng tổng quát hóa của mô hình trên từng bài toán.

3.2. Kết quả thực nghiệm

3.2.1. Bài toán phân loại rác thải

Đối với bài toán phân loại rác thải, 4 nhóm rác được định nghĩa cụ thể: Rác hữu cơ bao gồm phế phẩm thực phẩm, rau củ; Rác tái chế gồm chai chai nhựa, vỏ lon, bìa giấy; Rác nguy hại

gồm pin, đèn, rác y tế, vỏ chai hóa chất; Rác vô cơ gồm hộp xốp, túi ni lông bẩn, vỏ bánh kẹo, giày dép, khẩu trang...

Nghiên cứu sử dụng bộ dữ liệu gồm 1300 ảnh được thu thập bằng cách tự chụp và lấy ảnh trên Kaggle. Dữ liệu được tiền xử lý, gán nhãn và chia thành ba tập dữ liệu gồm 1000 ảnh huấn luyện (chiếm 76.9% tổng số dữ liệu), 148 ảnh kiểm định (chiếm 11.3% tổng số dữ liệu) và 152 ảnh kiểm tra (chiếm 11.8% tổng số dữ liệu) chi tiết ở Bảng 1. Mô hình được xây dựng dựa trên kiến trúc VGG-16 và được huấn luyện trên nền tảng Google Colab sử dụng GPU đồng thời áp dụng kỹ thuật Early Stopping nhằm rút ngắn thời gian huấn luyện và nâng cao hiệu quả tính toán.


Bảng 1. Chi tiết số lượng hình ảnh phân chia theo nhãn dán

Loại nhãn	Tập dữ liệu huấn luyện	Tập dữ liệu kiểm định	Tập dữ liệu kiểm tra
Rác hữu cơ	250	37	38
Rác vô cơ	250	37	38
Rác nguy hại	250	37	38
Rác tái chế	250	37	38


Sau quá trình huấn luyện mô hình trên Google Colab, kết quả thực nghiệm ở Hình 5 có thể thấy mô hình hội tụ và có độ chính xác khá cao trên tập dữ liệu huấn luyện sau khi trải qua 8 vòng lặp huấn luyện (epoch). Đồng thời, độ chính xác trên tập dữ liệu kiểm định nằm ở mức tương đối ổn định, cho thấy mô hình có khả năng học tốt các đặc trưng của dữ liệu và đạt hiệu quả tương đối cao trong bài toán phân loại rác. Sự chênh lệch giữa độ chính xác của tập huấn luyện và tập kiểm định cho thấy mô hình có dấu hiệu quá khớp nhẹ. Tuy nhiên, với kết quả dự đoán trên tập kiểm tra

đạt độ chính xác 90.13%, mô hình vẫn đáp ứng khá tốt yêu cầu của bài toán phân loại rác.

Giá trị hàm mất mát trên tập huấn luyện giảm nhanh và dần ổn định qua các vòng lặp huấn luyện, phản ánh khả năng hội tụ tốt của mô hình (Hình 6). Trong khi đó, hàm mất mát trên tập kiểm định có sự dao động giữa các epoch nhưng nhìn chung vẫn duy trì ở mức tương đối thấp và không ảnh hưởng đáng kể đến hiệu quả phân loại. Kết quả này cho thấy mô hình VGG-16 có khả năng học và trích xuất hiệu quả các đặc trưng của dữ liệu ảnh, đồng thời đạt hiệu năng phân loại tốt trong bài toán phân loại rác.



Hình 5. Độ chính xác của mô hình sau 8 vòng lặp huấn luyện trên tập dữ liệu huấn luyện và tập dữ liệu kiểm định



Hình 6. Độ lỗi (loss) của mô hình sau 8 vòng lặp huấn luyện trên tập dữ liệu huấn luyện và tập dữ liệu kiểm định

Bảng 2. Kết quả đánh giá hiệu năng mô hình phân loại rác

	Rác hữu cơ	Rác vô cơ	Rác nguy hại	Rác tái chế
Precision	1	0.87	0.89	0.84
Recall	0.97	0.89	0.86	0.86
F1 score	0.98	0.88	0.87	0.85

Kết quả đánh giá cho thấy mô hình đạt hiệu năng tốt trên cả bốn lớp phân loại. Lớp rác hữu cơ có hiệu suất cao nhất với Precision = 1.00, Recall = 0.97 và F1-score = 0.98, chứng tỏ mô hình nhận diện rất chính xác lớp dữ liệu này. Ba lớp còn lại cũng đạt kết quả khả quan với F1-score lần lượt là 0.88 (rác vô cơ), 0.87 (rác nguy

hại) và 0.85 (rác tái chế). Mặc dù, lớp rác tái chế có hiệu năng thấp hơn các lớp còn lại, giá trị F1-score vẫn ở mức cao, cho thấy mô hình duy trì khả năng phân loại ổn định. Nhìn chung, F1-score trung bình đạt khoảng 0.90, khẳng định mô hình có độ tin cậy cao và đáp ứng tốt yêu cầu của bài toán phân loại rác thải thành bốn nhóm.

Bảng 3. Kết quả dự đoán của mô hình trên tập dữ liệu kiểm tra

	Rác hữu cơ	Rác vô cơ	Rác nguy hại	Rác tái chế
Thực tế	38	38	38	38
Dự đoán đúng	37	34	33	33
Tỉ lệ (%)	97.36	89.47	86.84	86.84

Kết quả dự đoán được biểu diễn ở Bảng 3 cho thấy mô hình đạt độ chính xác trung bình 90.13% trên tập kiểm tra. Mặc dù vẫn còn tồn tại một số trường hợp phân loại chưa chính xác có thể xuất phát từ nhiều nguyên nhân như dữ liệu đầu vào, sự tương đồng về đặc trưng giữa các loại rác.

3.2.2. Bài toán phân loại độ đục của nước

Đối với bài toán phân loại độ đục của nước, nghiên cứu sử dụng tập dữ liệu được thu thập bằng cách tự chụp gồm 465 ảnh thuộc năm mức độ đục là 0.1, 0.2, 0.3, 0.4 và 0.5. Sau khi thu thập, dữ liệu được tiền xử lý, gán nhãn, áp dụng kỹ thuật làm nhiễu bằng cách bổ sung các dạng nhiễu Gaussian Noise, Salt & Pepper Noise và Joint Noise nhằm tăng tính đa dạng của dữ liệu

và chia thành 465 ảnh huấn luyện, 50 ảnh kiểm định và 70 ảnh kiểm tra (Bảng 4). Mô hình VGG-16 được huấn luyện trên nền tảng Google Colab sử dụng GPU, đồng thời áp dụng kỹ thuật Early Stopping nhằm hạn chế hiện tượng quá khớp và lựa chọn mô hình có hiệu năng tốt nhất.

Dữ liệu được tổ chức theo từng thư mục trong drive, trong đó các tập train, val, và test đều chứa 5 thư mục con đại diện cho 5 lớp độ đục từ 0.1 đến 0.5. Để đảm bảo không rò rỉ dữ liệu, các file ảnh bên trong thư mục train được đặt tên có kiểu nhiễu tương ứng (ví dụ: sp_*, gauss_*, joint_*). Đảm bảo toàn bộ ảnh nhiễu nằm trong tập train, trong khi các tiền tố ở tập val và test hoàn toàn độc lập và chỉ chứa ảnh gốc nguyên bản.

Bảng 4. Chi tiết số lượng hình ảnh phân chia theo nhãn dán


Loại nhãn	Tập dữ liệu huấn luyện	Tập dữ liệu kiểm định	Tập dữ liệu kiểm tra
0.1	93	10	14
0.2	93	10	14
0.3	93	10	14
0.4	93	10	14
0.5	93	10	14

Sau quá trình huấn luyện mô hình trên Google Colab, kết quả thực nghiệm ở Hình 7 có thể thấy mô hình hội tụ và có độ chính xác tăng dần trên tập dữ liệu huấn luyện sau khi trải qua 15 vòng lặp huấn luyện. Đồng thời, độ chính xác trên tập dữ liệu kiểm định có sự dao động qua các epoch nhưng nhìn chung đạt mức tương đối cao và nằm ở mức ổn, với giá trị cao nhất khoảng 90% tại epoch 9. Điều này cho thấy mô hình có khả năng


học tốt các đặc trưng của dữ liệu và đạt hiệu quả tương đối cao trong bài toán phân loại độ đục của nước. Sự chênh lệch giữa độ chính xác của tập huấn luyện và tập kiểm định cho thấy mô hình có dấu hiệu quá khớp nhẹ. Tuy nhiên, với độ chính xác trên tập kiểm tra đạt 92,86%, mô hình vẫn đáp ứng khá tốt yêu cầu của bài toán phân loại độ đục của nước.

Giá trị hàm mất mát trên tập huấn luyện giảm nhanh và dần ổn định qua các vòng lặp huấn luyện, phản ánh khả năng hội tụ tốt của mô hình. Trong khi đó, hàm mất mát trên tập kiểm định có sự dao động giữa các epoch nhưng nhìn chung vẫn duy trì ở mức tương đối thấp và không ảnh

hưởng đáng kể đến hiệu quả phân loại. Kết quả này cho thấy mô hình VGG-16 có khả năng nhận diện tốt các đặc điểm của dữ liệu ảnh, đồng thời đạt hiệu năng phân loại tương đối cao trong bài toán phân loại rác.



Hình 7. Độ chính xác của mô hình sau 15 vòng lặp huấn luyện trên tập dữ liệu huấn luyện và tập dữ liệu kiểm định



Hình 8. Độ lỗi của mô hình sau 15 vòng lặp huấn luyện trên tập dữ liệu huấn luyện và tập dữ liệu kiểm định

Bảng 5. Kết quả đánh giá hiệu năng mô hình phân loại độ đục của nước

	0.1	0.2	0.3	0.4	0.5
Precision	0.93	0.84	1	1	0.86
Recall	1	0.79	1	0.86	1
F1 score	0.96	0.81	1	0.92	0.92

Kết quả đánh giá cho thấy mô hình đạt hiệu năng tốt trên cả năm lớp phân loại độ đục. Lớp độ đục 0.3 có hiệu suất cao nhất với Precision = 1.00, Recall = 1.00 và F1-score = 1.00, chứng tỏ mô hình nhận diện hoàn hảo lớp dữ liệu này. Bốn lớp còn lại cũng đạt kết quả khả quan với F1-score lần lượt là 0.96 (độ đục 0.1), 0.92 (độ đục 0.4), 0.92 (độ đục 0.5) và 0.81 (độ đục 0.2). Mặc

dù lớp độ đục 0.2 có hiệu năng thấp hơn các lớp còn lại tuy nhiên giá trị F1-score vẫn ở mức cao (với F1-score trung bình đạt 0.92), cho thấy mô hình duy trì khả năng phân loại ổn định. Nhìn chung, mô hình có độ tin cậy ở mức khá cao và đáp ứng tốt yêu cầu của bài toán phân loại độ đục của nước.

Bảng 6. Kết quả dự đoán của mô hình trên tập dữ liệu kiểm tra

	0.1	0.2	0.3	0.4	0.5
Thực tế	14	14	14	14	14
Dự đoán đúng	14	11	14	12	14
Tỉ lệ (%)	100	78.5	100	85.7	100

Kết quả dự đoán được biểu diễn ở Bảng 6 cho thấy mô hình đạt độ chính xác trung bình 92.86% trên tập dữ liệu kiểm tra. Mặc dù vẫn còn tồn tại một số trường hợp phân loại chưa chính xác ở hai lớp dữ liệu với tỷ lệ dự đoán đúng lần lượt là 78.5% (lớp 0.2) và 85.7% (lớp 0.4), có thể xuất phát từ sự tương đồng về đặc trưng giữa các mức độ đục của nước, điều kiện thu thập hình ảnh hoặc chất lượng ảnh đầu vào. Nhìn chung, mô hình VGG-16 vẫn đạt hiệu quả khá cao trong bài toán phân loại độ đục của nước, thể hiện qua việc 3/5 lớp dữ liệu (0.1, 0.3, 0.5) được dự đoán chính xác 100% và chỉ có 2/5 lớp xuất hiện mẫu dự đoán sai.

4. Kết luận

Bài báo đã áp dụng mô hình VGG-16 để nhận dạng hình ảnh trong bài toán phân loại rác và phân loại độ đục của nước. Kết quả thực nghiệm cho thấy mô hình VGG-16 đạt độ chính xác 90.13% đối với bài toán phân loại rác và 92.86% đối với bài toán phân loại độ đục của nước. Các kết quả này cho thấy VGG-16 có khả năng học và

trích xuất đặc trưng hiệu quả từ dữ liệu ảnh, đồng thời duy trì hiệu năng phân loại tốt trên các tập dữ liệu có đặc điểm khác nhau. Bên cạnh đó, quá trình huấn luyện cho thấy mô hình có khả năng hội tụ ổn định sau nhiều vòng lặp, trong khi kết quả đánh giá trên tập kiểm tra phản ánh khả năng tổng quát hóa tương đối tốt.

Mặc dù, đạt được những kết quả khả quan, nghiên cứu vẫn còn một số hạn chế. Quy mô tập dữ liệu còn tương đối nhỏ, chưa phản ánh đầy đủ sự đa dạng của dữ liệu trong điều kiện thực tế.

Tài liệu tham khảo

- [1] Haykin, S. S. (2009). *Neural networks and learning machines* (3rd ed.). Pearson Education.
- [2] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.
- [3] Rosenblatt, F. (1958). The perceptron: A probabilistic model for information storage and organization in the brain. *Psychological Review*, 65(6), 386–408.
<https://doi.org/10.1037/h0042519>

- [4] LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436–444. <https://doi.org/10.1038/nature14539>
- [5] Wu, T., Zhang, H., Peng, W., Lü, F., & He, P. (2022). Applications of convolutional neural networks for intelligent waste identification and recycling: A review. *Resources, Conservation and Recycling*, 190, 106813. <https://doi.org/10.1016/j.resconrec.2022.106813>
- [6] Lin, K., Zhou, T., Gao, X., Li, Z., Duan, H., Wu, H., Lu, G., & Zhao, Y. (2022). Deep convolutional neural networks for construction and demolition waste classification: VGGNet structures, cyclical learning rate, and knowledge transfer. *Journal of Environmental Management*, 318, 115501. <https://doi.org/10.1016/j.jenvman.2022.115501>
- [7] Soto, I. L., Concha-Sánchez, Y., & Raya, A. (2025). An image-based water turbidity classification scheme using a convolutional neural network. *Computation*, 13(8), 178. <https://doi.org/10.3390/computation13080178>
- [8] Nie, Y., Chen, Y., Guo, J., Li, S., Xiao, Y., Gong, W., & Lan, R. (2025). An improved CNN model in image classification application on water turbidity. *Scientific Reports*, 15(1), 11264. <https://doi.org/10.1038/s41598-025-93521-4>
- [9] LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11), 2278–2324. <https://doi.org/10.1109/5.726791>
- [10] Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2017). ImageNet classification with deep convolutional neural networks. *Communications of the ACM*, 60(6), 84–90. <https://doi.org/10.1145/3065386>
- [11] Simonyan, K., & Zisserman, A. (2015). Very deep convolutional networks for large-scale image recognition. *International Conference on Learning Representations (ICLR)*. <https://arxiv.org/abs/1409.1556>
- [12] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 770–778).
- [13] Bishop, C. M. (2006). *Pattern recognition and machine learning*. Springer.